

Mémoire de séries temporelles

Vamoussa KONATE, Nicolas ROQUES, Mohamed Ethmane AHMEDOU, Zié COULIBALY

28 mars 2025

Contents

1	Introduction	2
2	Visualisation des séries temporelles	2
3	Analyse des ventes de gazole	2
3.1	Décomposition de la série	2
3.2	Transformations et stationnarisation	4
3.3	Choix du modèle SARIMA	5
3.4	Diagnostics du modèle	6
3.5	Prédiction sur un an des ventes de gazole	7
4	Analyse des ventes de supercarburant	9
4.1	Test de stationnarité et décomposition	9
4.2	Stationnarisation et différenciation	11
4.3	Modélisation SARIMA et ajustement	11
4.4	Choix des paramètres	12
4.5	Diagnostics du modèle	13
4.6	Prédiction sur un an des ventes de supercarburant	14
5	Conclusion	15
A	Annexe	17
A.1	Code Python : Série des ventes de gazole (en kt)	17
A.2	Code R : Série des ventes mensuelles de supercarburant (en kt)	22

1 Introduction

Aujourd'hui, de nombreuses entreprises utilisent l'analyse de séries temporelles pour étudier l'évolution de phénomènes au fil du temps en identifiant tendances, saisonnalités et structures sous-jacentes. Ce projet vise à modéliser et prévoir les ventes mensuelles de gazole et de supercarburant à l'aide du modèle SARIMA. L'objectif est d'identifier les modèles les plus pertinents pour obtenir des prévisions fiables sur les 12 mois suivants.

2 Visualisation des séries temporelles




Figure 1: Évolution mensuelle des ventes de supercarburants auto et de gazole.

3 Analyse des ventes de gazole

La Figure 1 ci-dessus illustre l'évolution mensuelle des ventes de gazole (en kt) en France, de janvier 1981 à octobre 2024. On y observe :

- Une tendance globalement croissante,
- Une saisonnalité marquée par des variations récurrentes,
- Une amplitude des fluctuations qui augmente avec le niveau, suggérant une structure multiplicative,
- Une non-stationnarité due à une tendance et une variance non constante.

Ces observations indiquent qu'une transformation logarithmique serait appropriée pour stabiliser la variance avant modélisation.

3.1 Décomposition de la série

Comparons les décompositions additive et multiplicative.

Remarque : Dans la décomposition additive, l'amplitude saisonnière reste constante, tandis que notre série, présentant un niveau évolutif, est mieux décrite par la décomposition multiplicative, qui exprime la saisonnalité en pourcentage du niveau.




Figure 2: Comparaison des décompositions additive et multiplicative.

Nous en concluons que la série est non stationnaire, multiplicative, a une tendance croissante et une saisonnalité de période 12.

3.2 Transformations et stationnarisation

La série des ventes de gazole n'étant pas stationnaire (tendance marquée et variance variable), nous avons appliqué deux transformations :

- **Logarithmique** : stabilise la variance en atténuant l'effet d'une croissance du niveau.
- **Différenciation** : la première différence élimine la tendance et recentre la série autour de zéro.

La Figure 3 ci-dessous montre l'effet de ces opérations, avec une nette réduction de l'hétéroscédasticité et l'élimination de la tendance.





Figure 3: Effet de la transformation logarithmique et de la différenciation sur la série des ventes de gazole (en kt).

Les tests de stationnarité confirment que la série transformée est désormais stationnaire :

- **ADF** : Statistic = -5.62 , p-value = 1.16×10^{-6} (on rejette l'hypothèse de non-stationnarité).
- **KPSS** : Statistic = 0.424 , p-value = 0.067 (compatible avec la stationnarité au seuil de 5%).

Ainsi, la transformation logarithmique suivie d'une différenciation prépare efficacement la série pour une modélisation ARIMA/SARIMA.

3.3 Choix du modèle SARIMA



Après avoir comparé avec le modèle ARIMA, le modèle **SARIMA(1,1,2)(0,0,2)[12]** a été retenu. Nous avons choisi les paramètres en nous basant sur l'ACF et le PACF de la série log-différenciée.

- Paramètre q : Il est estimé à partir de l'ACF. On choisit q en fonction du nombre de lags significativement différents de zéro (au-delà des bandes bleues de confiance). En observant l'ACF de la série deux fois différenciée (une différenciation saisonnière et une différenciation non saisonnière), les 2 premiers lags sont significatifs. On peut donc proposer **$q = 2$**
- Paramètre p : Il est estimé à partir du PACF, en suivant la même logique que pour q . Les lags significatifs indiquent la valeur potentielle de p . Ici, le lag 1 ressortent nettement, donc **$p = 1$** .
- Paramètre d : Il correspond au nombre de différenciations non saisonnières. La série a été

différenciée une fois au lag 12, donc $\mathbf{d} = \mathbf{1}$

Les paramètres saisonniers P et Q sont choisis de la même manière que p et q , mais en tenant compte du lag correspondant à la saisonnalité. Dans ce cas, la période est de 12 (données mensuelles), ce qui signifie que l'analyse de l'ACF et de la PACF doit être effectuée à partir du lag 12.

Le paramètre D représente le degré de différenciation saisonnière. Ici, nous supposons que $D = 0$, ce qui signifie qu'aucune différenciation saisonnière n'est nécessaire.

- étermination de P : P est identifié en observant les pics significatifs de la PACF à partir du lag 12. Nous avons choisi $P = 0$, ce qui indique l'absence d'un effet saisonnier marqué. En effet, les observations séparées par une période saisonnière (12 mois pour des données mensuelles) ne présentent pas de dépendance directe : aucun pic significatif au lag 12 n'est visible dans la PACF, et aucune structure saisonnière claire n'apparaît.

- Détermination de Q : Q est déterminé en analysant les pics significatifs de l'ACF à partir du lag 12. Ici, nous choisissons $Q = 0$, car il n'existe pas de pic significatif au lag 12 et aucune structure saisonnière évidente n'est identifiable dans l'ACF.

- Différenciation non saisonnière : Nous supposons qu'aucune différenciation non saisonnière supplémentaire n'est nécessaire, soit $d = 0$.

En conclusion, l'absence de structure saisonnière claire dans les corrélogrammes (ACF et PACF) justifie le choix des paramètres saisonniers $P = 0$, $Q = 0$ et $D = 0$, ainsi que de la différenciation non saisonnière $d = 0$.

3.4 Diagnostics du modèle

Les diagnostics graphiques confirment la pertinence de ce modèle :

- **Trace temporelle (Figure 4)** : les résidus se comportent de manière aléatoire et autour de 0
- **Histogramme et densité (Figure 5)** : la distribution des résidus est proche d'une loi normale.
- **Q-Q Plot (Figure 6)** : les résidus suivent bien la droite de référence.
- **ACF (Figure 7)** : aucune autocorrélation systématique n'est détectée.




Figure 4: Trace temporelle des résidus.




Figure 5: Histogramme et densité des résidus.




Figure 6: Q-Q Plot des résidus.




Figure 7: ACF des résidus.

3.5 Prédiction sur un an des ventes de gazole

Les prévisions mensuelles pour les ventes de gazole, couvrant la période de Novembre 2024 à Octobre 2025, sont présentées dans le Tableau 1 et illustrées dans la Figure 8.

Mois	Prédiction (kt)
Nov 2024	2402.97
Dec 2024	2384.58
Jan 2025	2395.11
Feb 2025	2365.16
Mar 2025	2423.22
Apr 2025	2436.18
May 2025	2405.09
Jun 2025	2410.71
Jul 2025	2527.63
Aug 2025	2387.68
Sep 2025	2394.14
Oct 2025	2512.70

Table 1: Prévisions mensuelles des ventes de gazole (en kilotonnes).





Figure 8: Graphique des prévisions de ventes de gazole de Novembre 2024 à Octobre 2025.

4 Analyse des ventes de supercarburant

La série étudiée représente les ventes mensuelles de supercarburant, de janvier 1981 à octobre 2024.



Nous commençons par vérifier si la série est stationnaire.

4.1 Test de stationnarité et décomposition

À l'oeil nu, la série n'est pas stationnaire : elle présente une tendance globale à la baisse et une saisonnalité visible.


Le test de Dickey-Fuller augmenté confirme cela :

Augmented Dickey-Fuller Test

```
data: super_serie temporelle
Dickey-Fuller = 0.24636, Lag order = 8, p-value = 0.99
alternative hypothesis: stationary
```

La p-value est supérieure à 5 %, donc l'hypothèse de non-stationnarité est acceptée.


Autocorrélogramme Ventes de super carburant (en kt)



L'ACF diminue et augmente tous les 12 mois et montre des pics réguliers tous les 12 mois : la série est clairement saisonnière (période 12).

Supposons que la série soit additive :

Decomposition of additive time series




On observe une tendance décroissante, une saisonnalité régulière, une composante irrégulière (résidus).

Comme pour la série de gazole, nous allons utiliser un modèle SARIMA après transformation de la série.

4.2 Stationnarisation et différenciation

On applique une différenciation au lag 1 (non saisonnière) pour supprimer la tendance tout en conservant la saisonnalité :



Le test de Dickey-Fuller sur la série différenciée donne :

Augmented Dickey-Fuller Test


```
data: diff(super_serie temporelle)
Dickey-Fuller = -16.155, Lag order = 8, p-value = 0.01
alternative hypothesis: stationary
```

La p-value est inférieure à 5 %, donc la série est désormais stationnaire. ## Choix des paramètres


4.3 Modélisation SARIMA et ajustement

Nous estimons les paramètres du modèle SARIMA en observant l'ACF et le PACF de la série différenciée :

Autocorrélogramme de la série vente de Super carburant différenciée



Autocorrélogramme partiel de la série vente de Super carburant différenciée



4.4 Choix des paramètres

Nous avons essayé plusieurs combinaisons avant de trouver le bon modèle (modèle qui ne crée pas d'erreur et donne des bons résultats) en s'aidant sur les critères suivants, les mêmes critères que

pour la série des ventes de gazole étudiée.


- p : premier lag significatif dépassant les bandes bleues dans le PACF à partir du lag 1.
- q : premier lag significatif dépassant les bandes bleues dans l'ACF à partir du lag 1.
- $d = 1$: une différenciation a été appliquée
- P,D,Q : À évaluer à partir des lags multiples de 12, pareil que pour, p , q et d ensuite.
- $D = 0$: pas de différenciation saisonnière nécessaire ici (saisonnalité conservée)

Nous avons utilisé la fonction `arima()` et `method="ML"` dans la fonction `arima()` qui indique que l'estimation des paramètres du modèle SARIMA est réalisée par Maximum de Vraisemblance (ML). Cela signifie que l'algorithme cherche à maximiser la probabilité d'observer les données données les paramètres du modèle, ce qui permet d'obtenir des estimations optimales sous hypothèses statistiques.

Le meilleur modèle trouvé est : **SARIMA(6,1,1)(6,0,3)[12]**


4.5 Diagnostics du modèle

4.5.0.1 Test d'autocorrélation de Ljung-Box sur les résidus Le test de Ljung-Box appliqué aux résidus donne les résultats suivants :



Les résultats montrent que les résidus sont indépendants jusqu'au lag 60. On peut donc conclure qu'ils ne sont pas autocorrélés.

4.5.0.2 Test de normalité des résidus Voici le graphique QQ-plot des résidus :



Les résidus semblent globalement suivre une loi normale. Toutefois, la présence de quelques valeurs extrêmes pourrait affecter cette normalité. En les retirant, on observe une distribution encore plus proche de la normale.

4.6 Prédiction sur un an des ventes de supercarburant


Les valeurs prévues pour les 12 prochains mois sont données par (pred donne la prédiction et se l'erreur associée) :

\$pred	Jan	Feb	Mar	Apr	May	Jun	Jul
2024							
2025	923.1689	892.4751	889.3660	819.5109	893.2290	987.1538	1146.6050
	Aug	Sep	Oct	Nov	Dec		
2024				936.6073	960.6149		
2025	1088.5458	1018.7268	1016.7007				

\$se	Jan	Feb	Mar	Apr	May	Jun	Jul
2024							
2025	51.38267	53.06310	53.36189	53.93033	54.65582	56.35684	58.25912
	Aug	Sep	Oct	Nov	Dec		
2024				46.65937	49.52415		
2025	59.97844	61.53941	62.70907				

La courbe de prévision est affichée ci-dessous :

Forecasts from ARIMA(6,1,1)(6,0,3)[12]



Globalement, les prévisions respectent bien la structure de la série.

5 Conclusion

Nous avons analysé et modélisé les séries temporelles des ventes de gazole et de supercarburant en utilisant des modèles SARIMA adaptés à leur saisonnalité. Après stationnarisation et calibration des modèles, les prévisions obtenues respectent bien les tendances observées. Bien que perfectibles, ces modèles offrent une base pour anticiper l'évolution des ventes et guider la prise de décision.

ANNEXE

A Annexe

A.1 Code Python : Série des ventes de gazole (en kt)

1. Importation et préparation des données

```
1 import pandas as pd
2
3 df = pd.read_csv(
4     '/content/Data.csv',
5     header=1,
6     sep=';',
7     encoding='latin-1'
8 )
9
10 df.columns = df.columns.str.strip()
11 df['PERIODE'] = pd.to_datetime(df['PERIODE'], format='%Y-%m', errors='
    coerce')
12 df.set_index('PERIODE', inplace=True)
13
14 print("Aperçu des données :")
15 print(df.head())
16
17 print("\nInfos sur le DataFrame :")
18 print(df.info())
```

Listing 1: Lecture du fichier CSV et préparation de la série temporelle

2. Visualisation des ventes de gazole et supercarburants

```
1 import matplotlib.pyplot as plt
2
3 plt.figure(figsize=(12, 6))
4 plt.plot(df.index, df['VSUPERC_RAFF'], label='Ventes Supercarburants (en kt
    )', color='darkorange')
5 plt.plot(df.index, df['VGAZOL_RAFF'], label='Ventes Gazole (en kt)', color=
    'royalblue')
6
7 plt.title("Évolution mensuelle des ventes de supercarburants auto et de
    gazole")
8 plt.xlabel("Date")
9 plt.ylabel("Quantité (kt)")
10 plt.legend()
11 plt.grid(True)
12 plt.tight_layout()
13 plt.show()
```

Listing 2: Tracé de l'évolution mensuelle des ventes de gazole et de supercarburants

3. Décomposition saisonnière de la série de ventes de gazole

```
1 import matplotlib.pyplot as plt
2 from statsmodels.tsa.seasonal import seasonal_decompose
3
4 ts = df['VGAZOL_RAFF'].interpolate(method='linear').dropna().sort_index()
5
6 result_add = seasonal_decompose(ts, model='additive', period=12)
7 result_mult = seasonal_decompose(ts, model='multiplicative', period=12)
8
9 gray_color = '#323232'
10 line_width = 0.5
11
12 # D composition additive
13 fig, axs = plt.subplots(4, 1, figsize=(10, 8), sharex=True)
14 axs[0].plot(result_add.observed, color=gray_color, linewidth=line_width)
15 axs[0].set_title('Observ ', color=gray_color)
16 axs[1].plot(result_add.trend, color=gray_color, linewidth=line_width)
17 axs[1].set_title('Tendance', color=gray_color)
18 axs[2].plot(result_add.seasonal, color=gray_color, linewidth=line_width)
19 axs[2].set_title('Saisonnalit ', color=gray_color)
20 axs[3].plot(result_add.resid, color=gray_color, linewidth=line_width)
21 axs[3].set_title('R sidus', color=gray_color)
22 plt.suptitle('D composition additive des ventes de gazole', color=
    gray_color, fontsize=16)
23 plt.tight_layout(rect=[0, 0.03, 1, 0.95])
24 plt.show()
25
26 # D composition multiplicative
27 fig, axs = plt.subplots(4, 1, figsize=(10, 8), sharex=True)
28 axs[0].plot(result_mult.observed, color=gray_color, linewidth=line_width)
29 axs[0].set_title('Observ ', color=gray_color)
30 axs[1].plot(result_mult.trend, color=gray_color, linewidth=line_width)
31 axs[1].set_title('Tendance', color=gray_color)
32 axs[2].plot(result_mult.seasonal, color=gray_color, linewidth=line_width)
33 axs[2].set_title('Saisonnalit ', color=gray_color)
34 axs[3].plot(result_mult.resid - 1, color=gray_color, linewidth=line_width)
35 axs[3].set_title('R sidus (centr s)', color=gray_color)
36 plt.suptitle('D composition multiplicative des ventes de gazole', color=
    gray_color, fontsize=16)
37 plt.tight_layout(rect=[0, 0.03, 1, 0.95])
38 plt.show()
```

Listing 3: Décomposition additive et multiplicative de la série VGAZOL_RAFF

4. Transformation logarithmique et différenciation de la série

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3
```

```

4 ts_log = np.log(ts)
5 ts_log_diff = ts_log.diff().dropna()
6
7 plt.figure(figsize=(12, 10))
8
9 plt.subplot(3, 1, 1)
10 plt.plot(ts, color='blue')
11 plt.title('Série originale des ventes de gazole (en kt)')
12 plt.xlabel('Date')
13 plt.ylabel('Ventes')
14
15 plt.subplot(3, 1, 2)
16 plt.plot(ts_log, color='orange')
17 plt.title('Série log-transformée des ventes de gazole')
18 plt.xlabel('Date')
19 plt.ylabel('Log(Ventes)')
20
21 plt.subplot(3, 1, 3)
22 plt.plot(ts_log_diff, color='green')
23 plt.title('Première différence de la série log-transformée')
24 plt.xlabel('Date')
25 plt.ylabel('Différence de log(Ventes)')
26
27 plt.tight_layout()
28 plt.show()

```

Listing 4: Transformation log et différenciation de la série VGAZOL_RAFF

5. Tests de stationnarité et autocorrélations de la série différenciée

```

1 from statsmodels.tsa.stattools import adfuller, kpss
2
3 adf_result = adfuller(ts_log_diff)
4 print("ADF Statistic: ", adf_result[0])
5 print("p-value: ", adf_result[1])
6 print("Critical Values:")
7 for key, value in adf_result[4].items():
8     print(f"    {key}: {value}")
9
10 kpss_result = kpss(ts_log_diff, regression='c', nlags="auto")
11 print("\nKPSS Statistic: ", kpss_result[0])
12 print("p-value: ", kpss_result[1])
13 print("Critical Values:")
14 for key, value in kpss_result[3].items():
15     print(f"    {key}: {value}")
16
17 import matplotlib.pyplot as plt
18 from statsmodels.graphics.tsaplots import plot_acf, plot_pacf
19
20 plt.figure(figsize=(12, 10))

```

```

21
22 plt.subplot(2, 1, 1)
23 plot_acf(ts_log_diff, lags=40, ax=plt.gca(), color='blue')
24 plt.title("ACF de la s r i e log-diff renci e")
25 plt.xlabel("D calages (lags)")
26 plt.ylabel("Autocorr lation")
27
28 plt.subplot(2, 1, 2)
29 plot_pacf(ts_log_diff, lags=40, ax=plt.gca(), color='green', method='ywm')
30 plt.title("PACF de la s r i e log-diff renci e")
31 plt.xlabel("D calages (lags)")
32 plt.ylabel("Autocorr lation partielle")
33
34 plt.tight_layout()
35 plt.show()

```

Listing 5: Tests ADF et KPSS, et analyse ACF/PACF sur la srie log-diffrencie

6. Ajustement du modle ARIMA et analyse des rsidus

```

1 import matplotlib.pyplot as plt
2 import seaborn as sns
3 import statsmodels.api as sm
4 from statsmodels.graphics.tsaplots import plot_acf
5
6 model = sm.tsa.statespace.SARIMAX(ts_log,
7                                   order=(1, 1, 2),
8                                   seasonal_order=(0, 0, 2, 12),
9                                   enforce_stationarity=False,
10                                  enforce_invertibility=False)
11 results = model.fit(dispatch=False)
12 print(results.summary())
13
14 residuals = results.resid
15
16 # 1. Trace temporel des r sidus
17 plt.figure(figsize=(12, 6))
18 plt.plot(residuals, color='blue')
19 plt.title("Trace temporel des r sidus")
20 plt.xlabel("Temps")
21 plt.ylabel("R sidus")
22 plt.show()
23
24 # 2. Histogramme et densit des r sidus
25 plt.figure(figsize=(8, 6))
26 sns.histplot(residuals, bins=20, kde=True, color='blue')
27 plt.title("Distribution des r sidus")
28 plt.xlabel("R sidus")
29 plt.ylabel("Fr quence")
30 plt.show()

```

```

31
32 # 3. Q-Q Plot des r sidus
33 plt.figure(figsize=(8, 6))
34 sm.qqplot(residuals, line='s')
35 plt.title("Q-Q Plot des r sidus")
36 plt.show()
37
38 # 4. ACF des r sidus
39 plt.figure(figsize=(10, 6))
40 plot_acf(residuals, lags=40, color='blue')
41 plt.title("ACF des r sidus")
42 plt.xlabel("Lag")
43 plt.ylabel("Autocorr lation")
44 plt.show()

```

Listing 6: et diagnostic des résidus]Ajustement du modèle SARIMAX(1,1,2)(0,0,2)[12] et diagnostic des résidus

7. Prédiction sur 12 mois avec modèle R et intégration Python

```

1  robjects.r(''
2      fc <- forecast(model, h=12)
3
4      fc$mean <- exp(fc$mean)
5      fc$lower <- exp(fc$lower)
6      fc$upper <- exp(fc$upper)
7
8      ts_sales <- exp(ts_log)
9
10     png("forecast_pred.png", width=800, height=600)
11     plot(ts_sales, col="blue", lwd=2, main="Pr vision sur 12 mois", xlab="
        Temps", ylab="Ventes",
12         ylim=c(min(ts_sales, fc$lower), max(ts_sales, fc$upper)))
13     lines(fc$mean, col="red", lwd=2)
14
15     polygon(c(time(fc$mean), rev(time(fc$mean))),
16            c(fc$upper[,2], rev(fc$lower[,2])),
17            col=rgb(1, 0, 0, 0.2), border=NA)
18     dev.off()
19     '')
20
21 import numpy as np
22 import pandas as pd
23
24 fc_mean = np.array(robjects.r('as.vector(fc$mean)'))
25 fc_lower = np.array(robjects.r('as.vector(fc$lower[,2])'))
26 fc_upper = np.array(robjects.r('as.vector(fc$upper[,2])'))
27 fc_time = np.array(robjects.r('as.vector(time(fc$mean))'))
28
29 forecast_df = pd.DataFrame({

```

```

30     'Time': fc_time,
31     'Forecast': fc_mean,
32     'Lower 95%': fc_lower,
33     'Upper 95%': fc_upper
34 })
35
36 print("Pr visions sur 12 mois (en ventes) :")
37 print(forecast_df)
38
39 from IPython.display import Image, display
40 display(Image("forecast_pred.png"))

```

Listing 7: Prévision sur 12 mois via R (forecast), conversion en ventes réelles, et affichage depuis Python

A.2 Code R : Série des ventes mensuelles de supercarburant (en kt)

1. Construction de la série temporelle et visualisation initiale

```

1 library(tseries)
2 library(forecast)
3
4 dates = seq(as.Date("1981/1/1"), as.Date("2024/10/1"), by = "month")
5
6 # Vecteur des ventes (donn es supprim es ici pour all ger)
7 super_serie temporelle = ts(super, frequency = 12, start = c(1981, 1), end =
8   c(2024, 10))
9 plot(super_serie temporelle, main = "Ventes de super carburant (en kt)")

```

Listing 8: Création de la série temporelle et tracé des ventes de supercarburant

2. Test de stationnarité et autocorrélogramme

```

1 adf.test(super_serie temporelle)
2
3 Acf(super_serie temporelle, main = "Autocorr logramme des ventes de super
4   carburant (en kt)")

```

Listing 9: Test ADF et autocorrélogramme de la série originale

3. Décomposition de la série

```

1 plot(decompose(super_serie temporelle, type = "additive"))

```

Listing 10: Décomposition additive de la série temporelle

4. Différenciation de la série et nouvelles analyses

```
1 plot(diff(super_serie_temporelle), main = "Série des ventes de super  
   carburant différenciée")  
2  
3 adf.test(diff(super_serie_temporelle))  
4  
5 Acf(diff(super_serie_temporelle), main = "ACF de la série différenciée")  
6  
7 Pacf(diff(super_serie_temporelle), main = "PACF de la série différenciée"  
   )
```

Listing 11: Différenciation et nouveaux tests de stationnarité et autocorrélogrammes

5. Ajustement du modèle SARIMA et diagnostic

```
1 sarima3 <- arima(super_serie_temporelle, order = c(6, 1, 1), seasonal = list  
   (order = c(6, 0, 3)), method = "ML")  
2 sarima3  
3  
4 tsdiag(sarima3, gof.lag = 100)  
5 qqnorm(sarima3$residuals)  
6 qqline(sarima3$residuals)
```

Listing 12: Ajustement du modèle ARIMA et diagnostic des résidus

6. Prévision à 12 mois

```
1 predict(sarima3, n.ahead = 12)  
2 plot(forecast(sarima3, h = 12))
```

Listing 13: Prévision sur 12 mois à partir du modèle ajusté